

CNNを用いた深層学習による電波伝搬推定の一検討 —入力するマップパラメータと推定精度の関係—

今井 哲朗 浅井 孝浩

株式会社 NTT ドコモ 〒239-8536 神奈川県横須賀市光の丘 3-6

E-mail: imaite@nttdocomo.com

あらまし 近年の人工知能の発展は目覚ましく、現在、多くの応用研究が注目を集めている。その基礎となっている主な技術がディープラーニング（深層学習）である。そこで、筆者らも CNN を用いた深層学習による電波伝搬推定モデルを提案している。本稿では、CNN へ入力するマップパラメータに対する提案するモデルの動作を評価する。

キーワード 深層学習, ディープニューラルネットワーク, 機械学習, 電波伝搬推定

A Study on Radio Propagation Prediction by Using Deep Learning with CNN - Relationship between Prediction Accuracy and Input Map-Parameters -

Tetsuro IMAI and Takahiro ASAI

NTT DOCOMO, INC. 3-6 Hikari-no-oka, Yokosuka-shi, Kanagawa, 239-8536, Japan

E-mail: imaite@nttdocomo.com

Abstract Recently, advancement of artificial intelligence has been remarkable, and many applied researches are attracting attention now. Most of them are based on deep learning. Here, we have proposed radio propagation prediction model by using deep neural network with CNN. This paper evaluates behavior of the proposed model for map-parameters input to CNN.

Keywords Deep learning, Deep neural network, Machine learning, Radio propagation prediction

1. はじめに

近年の人工知能の発展は目覚ましく、現在、多くの応用研究が注目を集めている。その基礎となっている技術に深層学習（ディープラーニング）がある。深層学習は多層化したニューラルネットワーク（Deep Neural Network: DNN）を用いる機械学習の方法論であり、音声認識や画像認識、自然言語処理等の性能の飛躍的な向上に成功している[1-3]。

DNN の構成法は様々であるが、画像認識では特に畳み込みニューラルネットワーク（Convolutional Neural Network: CNN）をベースとするのが一般的である[1-3]。CNN は画像形状を維持して空間情報を活かしながら画像の特徴を認識する。一方、従来のニューラルネットワークによる伝搬推定法は、全結合ニューラルネットワーク（Fully Connected Neural Network: FNN）がベースとなっている[4,5]。ここで、FNN への入力パラメータは提案者が事前検討したものであり、その種類は様々である。そこで、筆者等が文献[6]にて提案したのが、“CNNを用いた深層学習による電波伝搬推定モデル”である。本モデルは、前段の CNN による都市構造パラメータ抽出部に住宅地図等のマップデータを入

力して伝搬推定に寄与するパラメータを自動抽出し、その出力を後段の FNN による伝搬推定部にシステムパラメータ（送受信間距離等）をと共に入力して伝搬損失を出力するものである。ここで、筆者らがマクロセル環境を前提に提案モデルの性能を評価したところ、学習精度は極めて良いが、推定精度は未だ十分ではないとの結論となった。なお、文献[7,8]では筆者らと同様のモデルを用いてオープンスクウェアのスマールセル環境を対象に検討しているが、得られている性能は筆者等と同様である。

提案モデルの推定精度を向上させるためには、① DNN の構成、② DNN 内で設定するパラメータ（ハイパーパラメータ）、③ DNN に入力するパラメータ、等の最適化が必要である。本稿では、③について、特に CNN へ入力するマップパラメータに対する提案モデルの振る舞いについて検討したので報告する。

2. 評価モデル

2.1. DNN 構成

評価には文献[6]で提案した図 1 の DNN 構成による伝搬推定モデルを用いる（ただし、フィルタの数は異




図1 評価モデルの DNN 構成

なる)。以下、本 DNN 構成について簡単に説明する。


都市構造パラメータ抽出部は 4 つの畳み込み層 (C 層) : $C_0 \sim C_3$ と 2 つのプーリング層 (P 層) : P_0, P_1 , 2 つの全結合層 (F 層) : F_0, F_1 より構成している。ここで、入力の “ 64×64 ” は入力するマップのサイズであり、“ N_{in} ” はマップの数 (ノ種類) を表している。この入力に対して、 C_0 の畳み込み演算 (フィルタサイズ: 5×5 , フィルタ数: 48) の出力として得られるものが右隣のマップ (サイズ: 60×60 , マップ数: 48) である。次のプーリング演算では C_0 の出力に対して小領域を 4×4 とするプーリング演算 (ただし、Average プーリング) を行う。その出力がさらに右隣のマップ (サイズ: 15×15 , マップ数: 48) である。以下、同様に畳み込み演算とプーリング演算を繰り返して C_3 層の出力として得られるのがサイズ: 2×2 のマップであり、その数は 6 である。ここで得られたサンプル ($24 = 2 \times 2 \times 6$) を F 層に入力し、CNN として最終的に 10 個の出力を得る。以上、都市構造パラメータ抽出部では、マップデータ (全サンプル数: $64 \times 64 \times N_{in}$) から 10 種類の都市構造パラメータを求めるようになっている。

伝搬推定部には 3 層 (入力層, 中間層, 出力層) の FNN を適用する。入力層には、都市構造パラメータ抽出部からの出力にシステムパラメータを加えたものが入力される。ここで、文献[6]ではシステムパラメータとして、“送受信間距離”と“見通し有無”を入力したが、本検討では CNN へ入力するマップパラメータの振る舞いを評価するために、システムパラメータは考慮しない。したがって、伝搬推定部への“入力パラメータ数は 10”である。本構成ではこれらの入力に対して伝搬損失の推定値を出力する。なお、システムパラメータを考慮していないことから、図 1 の DNN 構成は、4 つの C 層と 2 つの P 層および 4 つの F 層より構成される CNN と見なすことができる。

2.2. 入力マップパラメータ

提案モデルへの入力データは、基地局 (BS) と移動

局 (MS) をペアとし、特に、CNN へは MS を中心とする矩形領域 ($128\text{m} \times 128\text{m}$) を 2m でメッシュ化した空間情報 (建物情報等) をマップデータとして入力する。以下では、本検討における空間情報のクリッピング方法、マップデータの種類について説明する。



(a) グローバル座標

(b) ローカル座標

図2 空間情報のクリッピング

(1) 空間情報のクリッピング

住宅地図から MS を中心とする空間情報を抽出する際に、文献[6]では図 2(a)に示すように BS の位置に依らないグローバル座標 (x_0 - y_0 座標) を用いた。本方法により抽出したデータを用いて学習をすると、伝搬推定に寄与するパラメータとして、周辺建物の統計量 (平均建物項, 建物占有面積率) に相当するものを抽出することは可能である。しかし、本来、伝搬における建物の寄与は、BS に向かって MS の前面にあるものと背面や脇にあるものとは物理的に異なる。そこで、本検討では、空間情報を図 2(b)に示すローカル座標 (x_m - y_m 座標) より抽出することとする。本ローカル座標は、MS に対して BS が必ず x_m 軸上の正方向に存在するように定義したものである。したがって、本方法を用いれば、学習に BS や MS の異なるデータを用いても“BS 方向の情報”を間接的に加味することが可能となり、推定性の向上が期待できる。

(2) マップデータの種類

文献[6]では、マップデータとして、“建物マップ：各メッシュにおける建物の高さ情報より構成されたマップであり、建物の存在しないメッシュは0mと定義”と“見通しマップ：基地局に対する各メッシュの見通し有無の情報より構成されマップ”を用いた。これらの情報はMS周辺の建物情報を表現してはいるものの、伝搬としての物理的な情報は含まれていない。そこで、本検討ではより物理的な意味を考慮して、

- BS 距離マップ：BS から各メッシュまでの距離の情報で構成されたマップ。
- MS 距離マップ：MS から各メッシュまでの距離の情報で構成されたマップ。
- 建物マップ：各メッシュにおける建物の高さ情報より構成されたマップ。ただし、高さはフレネルゾーンの中心の高さを基準。

をマップデータとして評価の対象とする。

図3はあるサンプルデータにおけるBS距離マップとMS距離マップの例である。BS距離マップは前述のローカル座標基準でクリッピングをしていることから、図の右方向(x_m 軸の正方向)に行くほど値が小さくなっている。一方、MS距離マップはMSの存在する中心に向かって値が小さくなっている。

次に建物マップの高さの基準について述べる。建物の高さの基準としては、Walfish-池上式[9]のようにMSアンテナの高さからの相対値で定義することが考えられる。具体的には、各メッシュの高さを H_i とし、移動局アンテナ高を h_m とすると、その相対値は

$$\Delta H_i = H_i - h_m \quad (1)$$


で与えられる。ここで、伝搬における建物の寄与は回折を含む散乱であることを考えると、MSアンテナ高基準では十分とは言えない。そこで、本検討では、各メッシュでの1回散乱を仮定した際のフレネルゾーンの中心の高さを基準（以降、フレネル基準と呼ぶ）とすることを提案する。具体的には、図4に示すように、各メッシュへのBSおよびMSからの距離をそれぞれ $d_b^{(i)}$, $d_m^{(i)}$ 、BSアンテナ高を h_b とすると、1回散乱を仮定した際のフレネルゾーンの中心の高さ $H_F^{(i)}$ は

$$H_F^{(i)} = h_m + \frac{(h_b - h_m)d_m^{(i)}}{d_b^{(i)} + d_m^{(i)}} \quad (2)$$


与えられる。したがって、各メッシュの高さは

$$\Delta H_i = H_i - H_F^{(i)} \quad (3)$$

となる。式(3)を用いて求めた建物マップの例を図5に示す。本定義より得られる高さ ΔH_i は、正の値であれば散乱に寄与することを意味する。また、フレネル基準の建物マップの利点は、MSアンテナ高と共にBSアンテナ高も間接的に入力パラメータとして考慮できる点



(a) BS 距離マップ



(b) MS 距離マップ

図3 距離に関するマップの例




図4 フレネル基準による高さの定義




図5 建物マップの例

にある。すなわち、これらを伝搬推定モデルのシステムパラメータとして定義する必要が無い。

3. 評価方法

3.1. レイトレース計算

提案モデルの入力マップに対する性能を評価するため、筆者等が開発したレイトレースシミュレータ：3D-PRISM[10]を用いて、図6の都内青山エリアでレイトレース計算を実施した。計算条件を表1に示す。なお、基地局は図6に示す5局とし、計算ポイント(MS)は建物の配置されていない10mメッシュの中心とした。

3.2. 学習と検証用のデータ

DNNの学習には基地局5つ分の結果を用いる。ただし、議論を簡単にするために、“送受信間が見通し外かつ送受信間距離50m以上”のサンプル(2658ポイント)を対象とする。また、全体の10%を検証用データ(266ポイント)とし、残りを学習用データ(2392ポイント)とする。図7はこれらのデータの距離特性を示したものである。ここで、学習用データを送受信間距離 D で回帰すると、伝搬損失 $Loss$ は

$$Loss = 20.631 + 38.984 \log D \quad (4)$$

と表せる。また、式(4)を用いて検証用データを推定すると、RMS誤差：13.25dB、相関係数：0.34となる。

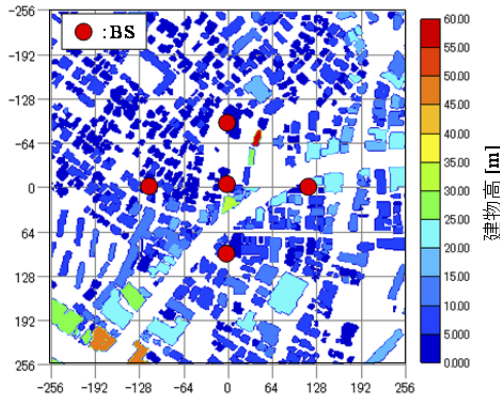


図6 レイトレース計算のエリア




図7 学習データと検証データ

表1 レイトレースの計算条件

パラメータ		設定値
周波数		2 GHz
Tx (BS)	アンテナ	理想アンテナ
	アンテナ高	40 m
Rx (MS)	アンテナ	理想アンテナ
	アンテナ高	1.5 m
建物 モデル	階高	3m/階
	材質	コンクリート: $\epsilon_r=6.76$, $\sigma=0.023$ S/m, $\mu_r=1$
反射・回折の回数		それぞれ最大1回 ただし、建物屋上回折: ∞ , 大地反射: 1
レイの加算		電力加算

3.3. 評価指標

本検討ではDNNの重みパラメータの学習にミニバッチ勾配降下法(バッチサイズ100)を用いることから、学習過程のイタレーション回数はエポック数(学習データ全体をイタレーションにより何回考慮したかを表す指標)で示すこととする。また、提案モデルの出力値に対しては、学習データおよび検証データとのRMS誤差と相関係数により評価する。なお、以下、推定結果は検証データの評価結果を指すものとする。

4. 評価結果

4.1. BS距離マップの効果

CNNへBS距離マップのみを入力した場合の学習の推移を図8に示す。図8(a)より、 $M=20$ を超えると学習データと検証データともにRMS誤差が13dB程度に収束していることが分かる。これは、イタレーション回数を増やしても過学習にも至らないことを示している。一方、図8(b)は最後のイタレーションにより得られた推定結果である。推定値は式(4)による計算値とほぼ同様の結果となっていることが分かる。また、推定値と検証データとの相関係数は0.35程度であり、式(4)による結果と同様である。したがって、CNNへBS距離マップのみを入力した場合、提案モデルは伝搬損失の距離特性を推定するように動作すると言える。

4.2. MS距離マップの効果

MS距離マップのみの場合、送受信間距離に対する情報が無いことから、伝搬損失の距離特性を求めることはできない。そこで、本マップの評価は伝搬損失を自由空間損失で規格化した超過損失(周辺建物による変動分)を対象に学習を実施した。

学習の推移は図8(a)と同様であることから、最後のイタレーションにより得られた推定結果のみを図9に示す。推定値は検証データ全体の平均値に収束してお

り、MS 距離マップは単独では推定においてほとんど意味が無いと言える。

4.3. 建物マップの効果

建物マップのみによる効果を評価した結果を図 10 に示す。ただし、MS 距離マップの評価と同様に、超過損失を対象に学習を実施したものである。

図 10(a)より、学習が進むにつれて学習データの RMS 誤差は 0dB に近づいていくが、検証データの方はある時 ($M=142.1$) を境に誤差が増加する方向に進むことが分かる。一方、図 10(b)は $M=142.1$ において得られた推定結果である。この時の RMS 誤差は 9.94dB、相関係数は 0.65 となっている。なお、推定値に自由空間損失分を加算して求めると相関係数は 0.70 となる。

ところで、建物高を MS アンテナ高基準にした場合やクリッピングにグローバル座標を用いた場合も学習の推移は図 10(a)と同様になる。これらの推定精度を比較した結果を表 2 に示す。表より、建物高にはフレネル基準を用い、かつクリッピングにローカル座標を用いることで精度が向上することが分かる。

4.4. 複数マップによる効果

最後に、全てのマップを入力した場合の結果を図 11 に示す。なお、本結果では超過損失ではなく、伝搬損失を対象に学習を実施している。

図 11(a)より、学習の推移は図 10(a)と同様であることが分かる。図 11(b)は、検証データの誤差が最小となる $M=84.156$ の時に得られた推定結果である。図より、伝搬損失が比較的良く推定できていることが分かる。この時の RMS 誤差は 10.05dB、相関係数は 0.69 であり、表 2 に項番 4 として示してある。


表 2 には項番 5 として、建物マップと BS 距離マップによる結果を示している。項番 4 と比較することにより、MS 距離マップは他のマップと組み合わせることにより推定精度の向上に寄与すると言える。

5. まとめ


本稿では、CNN を用いた深層学習による伝搬推定モデルにおいて、CNN へ入力するマップパラメータ (BS 距離マップ、MS 距離マップ、建物マップ) に対するモデルの性能を評価した。特に検討したマップは

- 住宅地図から MS を中心とする空間情報を抽出する場合、BS 方向が全てのデータで同一となるローカル座標を採用。
- 建物マップにおける建物の高さは、フレネルゾーンの中心の高さを基準と定義。

の特徴を持つ。また、各マップのモデルに対する振る舞いは次の通りである。



(a) 学習の推移



(b) 推定結果

図 8 BS 距離マップによる推定






図 9 MS 距離マップによる推定結果

- BS 距離マップ: 伝搬損失の距離特性 (長区間変動) の推定に寄与。
- 建物マップ: 周辺建物の影響による伝搬損失の短区間変動相当の推定に寄与。
- MS 距離マップ: 単独では意味を持たないが、他のマップとの組み合わせにより推定精度向上に寄与。




(a) 学習の推移




(b) 推定結果

図 10 建物マップによる推定



(a) 学習の推移



(b) 推定結果

図 11 3つのマップ（建物マップ，BS 距離マップ，MS 距離マップ）による推定

今後は，更なる精度を向上させるために，多層化ニューラルネットワークの構成およびネットワーク内パラメータの最適化について検討する予定である．

文 献

- [1] 岡谷貴之，“ディープラーニング,” 映像メディア学会誌, vol. 68, no. 6, pp. 466-471, 2014.
- [2] 岡谷貴之, 深層学習, 講談社, 2016.
- [3] 斎藤康毅, ゼロから作る Deep Learning, オライリー・ジャパン, 2017.
- [4] E. Östlin, H. Zepernick, H. Suzuki, “Macrocell Path-Loss Prediction Using Artificial Neural Networks,” IEEE Trans. VT, vol. 59, no. 6, pp. 2735-2747, July 2010.
- [5] M. Ayadi, A. Ben Zineb, and S. Tabbane, “A UHF Path Loss Model Using Learning Machine for Heterogeneous Networks,” IEEE Trans. AP, vol. 65, no. 7, pp. 3675-3683, July 2017.
- [6] 今井哲朗, 奥村幸彦, “ディープラーニングを用いた電波伝搬推定に関する一検討,” 信学技報, AP2017-165, pp81-86, Jan. 2018.
- [7] 久野 伸晃, 佐々木 元晴, 鷹取 泰司, “畳み込みニューラルネットワークを用いた深層学習による伝搬損失特性推定法,” 信学技報, AP2018-21, pp47-51, May 2018.

表 2 推定結果の比較

項番	クリッピング	入力マップ			RMS誤差 (dB)	相関係数
		建物	BS距離	MS距離		
1	ローカル	○ (フレネル)	—	—	9.94	0.65 (0.70)*
2	グローバル	○ (フレネル)	—	—	10.48	0.60 (0.66)*
3	ローカル	○ (MS高)	—	—	10.51	0.60 (0.65)*
4	ローカル	○ (フレネル)	○	○	10.05	0.69
5	ローカル	○ (フレネル)	○	—	10.47	0.66

※自由空間損失を考慮した際の値

- [8] 久野 伸晃, 山田 渉, 佐々木 元晴, 鷹取 泰司, 中村宏之, “畳み込みニューラルネットワークを用いた複数の遮蔽物を考慮した伝搬損失特性推定法,” 2018 信学ソ大, B-1-29, Sep. 2018.
- [9] 細矢良雄 (監修), 電波伝搬ハンドブック, リアライズ社, 1999.
- [10] 今井哲朗, 電波伝搬解析のためのレイトレーシング法, コロナ社, 2016.